

بررسی روش‌های یادگیری ماشین در تشخیص تقلب مالی

نام نویسنده: امیرحسین رنجبر

چکیده

تشخیص تراکنش‌های مالی تقلبی یکی از مسائل مهم در حوزه یادگیری ماشین است. نامتوازن بودن داده‌ها، تعداد بسیار کم نمونه‌های تقلبی و هزینه بالای تشخیص نادرست از جمله چالش‌های اصلی این مسئله هستند.

در این گزارش، ابتدا چند مدل پایه شامل درخت تصمیم، KNN و رگرسیون لجستیک بررسی می‌شوند. سپس مدل‌های پیشرفته‌تر شامل XGBoost و جنگل تصادفی مورد بررسی قرار می‌گیرند. همچنین مدل‌های مختلف در یک روش Ensemble ترکیب می‌شوند.

عملکرد مدل‌ها با استفاده از معیارهایی مانند Precision، Recall، F1-score و PR-AUC ارزیابی می‌شود. همچنین برای انتخاب تنظیمات مناسب مدل‌ها از روش‌های اعتبارسنجی متقابل و بهینه‌سازی هایپرپارامترها استفاده می‌شود.

واژگان کلیدی: یادگیری ماشین، تشخیص تقلب، تراکنش مالی، درخت تصمیم، KNN، رگرسیون لجستیک، جنگل تصادفی، XGBoost، Ensemble، Boost، داده‌های نامتوازن

۱. مقدمه

افزایش استفاده از سامانه‌های پرداخت الکترونیکی باعث شده است که حجم بسیار زیادی از تراکنش‌های مالی در هر روز ثبت شود. در کنار این افزایش، احتمال وقوع تراکنش‌های تقلبی نیز وجود دارد.

تشخیص خودکار تراکنش‌های تقلبی می‌تواند نقش مهمی در کاهش خسارت‌های مالی داشته باشد. با این حال، مسئله تشخیص تقلب معمولاً با مشکل نامتوازن بودن کلاس‌ها مواجه است.

در بسیاری از مجموعه‌داده‌های واقعی، تعداد تراکنش‌های سالم بسیار بیشتر از تراکنش‌های تقلبی است. بنابراین یک مدل ممکن است دقت بسیار بالایی داشته باشد، اما در تشخیص نمونه‌های تقلبی عملکرد مناسبی نداشته باشد.

به همین دلیل، در این مسئله معیارهایی مانند Precision، Recall، F1-score و PR-AUC اهمیت زیادی پیدا می‌کنند.

در این پژوهش، ابتدا مدل‌های پایه بررسی شده و سپس مدل‌های پیشرفته‌تر و در نهایت روش Ensemble مورد استفاده قرار گرفته‌اند.

۲. معرفی داده‌ها

در این پژوهش از یک مجموعه‌داده شامل تراکنش‌های مالی استفاده شده است. هر نمونه شامل تعدادی ویژگی مربوط به تراکنش و یک برچسب دودویی است.

برچسب صفر نشان‌دهنده تراکنش سالم و برچسب یک نشان‌دهنده تراکنش تقلبی است.

یکی از ویژگی‌های مهم داده، عدم توازن شدید بین دو کلاس است. به همین دلیل، استفاده از Accuracy به‌تنهایی نمی‌تواند معیار مناسبی برای ارزیابی مدل باشد.

داده‌ها پس از انجام مراحل پیش‌پردازش به دو مجموعه آموزش و آزمون تقسیم شدند.

۳. پیش‌پردازش داده‌ها

پیش از آموزش مدل‌ها، داده‌ها بررسی و آماده‌سازی شدند. مراحل پیش‌پردازش شامل بررسی مقادیر گمشده، داده‌های تکراری و آماده‌سازی ویژگی‌ها برای ورود به مدل است.

همان‌طور که در بررسی اولیه داده‌ها مشاهده شد، مجموعه‌داده دارای تعدادی مقدار تکراری بود. از آنجا که وجود داده‌های تکراری می‌تواند بر فرآیند آموزش مدل تأثیر بگذارد، این نمونه‌ها شناسایی و حذف شدند.

تعداد نمونه‌ها و تراکنش‌های تقلبی قبل و بعد از حذف داده‌های تکراری در جدول زیر ارائه شده است.

جدول ۱: مقایسه داده‌ها قبل و بعد از حذف نمونه‌های تکراری

After	Before	Data
۲۸۴۳۱۵	۲۸۴۸۰۷	transactions Total
۴۷۳	۴۹۲	transactions Fraudulent

همان‌طور که مشاهده می‌شود، تعداد کل تراکنش‌ها از ۲۸۴۸۰۷ به ۲۸۴۳۱۵ کاهش یافته است. همچنین تعداد تراکنش‌های تقلبی از ۴۹۲ نمونه به ۴۷۳ نمونه رسیده است. داده‌ها به دو مجموعه آموزش و آزمون تقسیم شدند:

$$D = D_{\text{train}} \cup D_{\text{test}}$$

به‌طوری‌که مجموعه آزمون در فرآیند آموزش مدل استفاده نمی‌شود.

در صورت وجود ویژگی‌هایی با مقیاس‌های متفاوت، می‌توان از روش‌های استانداردسازی برای آماده‌سازی داده‌ها استفاده کرد. استانداردسازی به‌خصوص برای مدل‌هایی مانند KNN و رگرسیون لجستیک اهمیت دارد.

۴. مدل‌های پایه

در مرحله اول پژوهش، سه مدل پایه برای ایجاد یک معیار اولیه از عملکرد سیستم مورد بررسی قرار گرفتند:

- درخت تصمیم

- KNN

- رگرسیون لجستیک

هدف از استفاده از مدل‌های پایه، بررسی عملکرد الگوریتم‌های مختلف و ایجاد مبنایی برای مقایسه با مدل‌های پیشرفته‌تر است.

۱.۴. درخت تصمیم

درخت تصمیم یکی از الگوریتم‌های یادگیری ماشین است که با تقسیم متوالی داده‌ها بر اساس ویژگی‌های مختلف، ساختاری درختی برای انجام پیش‌بینی ایجاد می‌کند.

پیچیدگی و عملکرد این مدل به هایپرپارامترهای مختلفی وابسته است. در این آزمایش، سه هایپرپارامتر مهم شامل max_depth، min_samples_split و min_samples_leaf مورد بررسی قرار گرفتند.

هایپرپارامتر max_depth حداکثر عمق درخت را مشخص می‌کند. افزایش این مقدار امکان ایجاد ساختارهای پیچیده‌تر را فراهم می‌کند، اما افزایش بیش از حد آن می‌تواند باعث بیش‌برازش شود. برای این پارامتر مقادیر ۳، ۵، ۸، ۱۰، ۱۵، ۲۰ و None بررسی شدند.

پارامتر min_samples_split حداقل تعداد نمونه‌های مورد نیاز برای انجام تقسیم یک گره را مشخص می‌کند. مقادیر ۲، ۵، ۱۰ و ۲۰ برای این پارامتر در نظر گرفته شدند.

پارامتر min_samples_leaf حداقل تعداد نمونه‌هایی را مشخص می‌کند که باید در هر گره برگ قرار داشته باشند. مقادیر ۱، ۲، ۵ و ۱۰ برای این پارامتر بررسی شدند.

برای انتخاب بهترین ترکیب از این هایپرپارامترها، از روش Grid Search استفاده شد.

برای $n_neighbors$ مقادیر ۳، ۵، ۷، ۹، ۱۱، ۱۵، ۲۰، ۲۵ و ۳۰ بررسی شدند.

در پارامتر $weights$ دو حالت $uniform$ و $distance$ بررسی شد. در حالت $distance$ ، نمونه‌های نزدیک‌تر وزن بیشتری در تصمیم‌گیری دارند.

پارامتر p نوع فاصله مورد استفاده را مشخص می‌کند. مقدار $p = 1$ متناظر با فاصله $Manhattan$ و مقدار $p = 2$ متناظر با فاصله $Euclidean$ است. در مجموع:

$$9 \times 2 \times 2 = 36$$

ترکیب مختلف بررسی شد.

برای ارزیابی هر ترکیب از Stratified K-Fold Cross Validation با پنج بخش استفاده شد و معیار انتخاب بهترین ترکیب F1-score بود.

جدول ۵: هایپرپارامترهای انتخاب شده برای KNN

هایپرپارامتر	مقادیر بررسی شده	مقدار انتخاب شده
$n_neighbors$	۳، ۵، ۷، ۹، ۱۱، ۱۵، ۲۰، ۲۵، ۳۰	۳
$weights$	$distance$ ، $uniform$	$distance$
p	۱، ۲	۱

در نتیجه، بهترین تنظیمات KNN شامل $K = 3$ ، وزن‌دهی $distance$ و فاصله $Manhattan$ ($p = 1$) بود.

مقدار بهترین F1-score در فرآیند اعتبارسنجی برابر با ۰/۸۵۴۳ به دست آمد.

پس از انتخاب هایپرپارامترها، مدل نهایی با استفاده از داده‌های آموزشی آموزش داده شد و سپس روی مجموعه آزمون ارزیابی گردید.

جدول ۶: نتایج مدل KNN روی مجموعه آزمون

Support	-scoreF	Recall	Precision	کلاس
۵۶۶۵۱	۱/۰۰	۱/۰۰	۱/۰۰	۰
۹۵	۰/۸۲	۰/۷۲	۰/۹۶	۱
۵۶۷۴۶	۰/۹۱	۰/۸۶	۰/۹۸	Avg Macro
۵۶۷۴۶	۱/۰۰	۱/۰۰	۱/۰۰	Avg Weighted

ماتریس درهم‌ریختگی مدل نیز به صورت زیر به دست آمد:

جدول ۷: ماتریس درهم‌ریختگی مدل KNN

پیش‌بینی کلاس ۰	پیش‌بینی کلاس ۱	واقعی کلاس ۰	واقعی کلاس ۱
۵۶۶۴۸	۳	۰	۶۸
۲۷	۶۸	۰	۶۸

بر اساس نتایج، مدل KNN برای کلاس اقلیت دارای Precision برابر با ۰/۹۶ و Recall برابر با ۰/۷۲ است.

مدل توانسته است ۶۸ مورد از مجموع ۹۵ تراکنش تقلبی را به درستی شناسایی کند، در حالی که ۲۷ نمونه تقلبی از دست رفته‌اند.

همچنین تنها ۳ تراکنش سالم به اشتباه به عنوان تقلب شناسایی شده‌اند. مقدار F1-score برابر با ۰/۸۲ است.

۳.۴. رگرسیون لجستیک

رگرسیون لجستیک یکی از روش‌های کلاسیک برای مسائل طبقه‌بندی دودویی است. این مدل ترکیب خطی ویژگی‌ها را محاسبه کرده و با استفاده از تابع سیگموئید احتمال تعلق نمونه به کلاس مثبت را به دست می‌آورد.

از آنجا که برای سه هایپرپارامتر به ترتیب ۷، ۴ و ۴ مقدار در نظر گرفته شد، در مجموع:

$$7 \times 4 \times 4 = 112$$

ترکیب مختلف مورد بررسی قرار گرفت.

برای ارزیابی هر ترکیب از Stratified K-Fold Cross Validation با پنج بخش استفاده شد. معیار F1-score به عنوان معیار انتخاب بهترین ترکیب در نظر گرفته شد.

در نهایت، بهترین ترکیب هایپرپارامترها به صورت زیر به دست آمد:

جدول ۲: هایپرپارامترهای انتخاب شده برای درخت تصمیم

هایپرپارامتر	مقادیر بررسی شده	مقدار انتخاب شده
max_depth	۳، ۵، ۸، ۱۰، ۱۵، ۲۰، None	۸
min_samples_split	۲، ۵، ۱۰، ۲۰	۲۰
min_samples_leaf	۱، ۲، ۵، ۱۰	۵

پس از انتخاب هایپرپارامترها، مدل نهایی با استفاده از داده‌های آموزشی آموزش داده شد و سپس روی مجموعه داده‌های آزمون ارزیابی گردید.

جدول ۳: نتایج مدل درخت تصمیم روی مجموعه آزمون

Support	-scoreF	Recall	Precision	کلاس
۵۶۶۵۱	۱/۰۰	۱/۰۰	۱/۰۰	۰
۹۵	۰/۸۰	۰/۷۱	۰/۹۲	۱
۵۶۷۴۶	۰/۹۰	۰/۸۵	۰/۹۶	Avg Macro
۵۶۷۴۶	۱/۰۰	۱/۰۰	۱/۰۰	Avg Weighted

همچنین ماتریس درهم‌ریختگی مدل به صورت زیر به دست آمد:

جدول ۴: ماتریس درهم‌ریختگی مدل درخت تصمیم

پیش‌بینی کلاس ۰	پیش‌بینی کلاس ۱	واقعی کلاس ۰	واقعی کلاس ۱
۵۶۶۴۵	۶	۰	۶۷
۲۸	۶۷	۰	۶۷

بر اساس نتایج، مدل برای کلاس اقلیت دارای Precision برابر با ۰/۹۲ و Recall برابر با ۰/۷۱ است.

مدل توانسته است ۶۷ مورد از مجموع ۹۵ نمونه مثبت را به درستی شناسایی کند، در حالی که ۲۸ نمونه مثبت به اشتباه به عنوان کلاس ۰ پیش‌بینی شده‌اند.

همچنین تنها ۶ نمونه از کلاس ۰ به اشتباه به عنوان کلاس ۱ شناسایی شده‌اند. مقدار F1-score برابر با ۰/۸۰ است.

۲.۴. K نزدیک‌ترین همسایه

الگوریتم KNN یکی از روش‌های مبتنی بر فاصله است که برای طبقه‌بندی یک نمونه جدید، نزدیک‌ترین نمونه‌های موجود در داده‌های آموزشی را بررسی می‌کند.

پارامتر $n_neighbors$ یا همان K ، تعداد همسایه‌هایی را مشخص می‌کند که در تصمیم‌گیری مورد استفاده قرار می‌گیرند.

از آنجا که KNN بر اساس فاصله بین نمونه‌ها عمل می‌کند، استانداردسازی ویژگی‌ها اهمیت زیادی دارد. در این پژوهش، داده‌های آموزشی پیش از استفاده در KNN استانداردسازی شدند.

برای انتخاب بهترین تنظیمات مدل، از Grid Search به همراه Stratified K-Fold Cross Validation استفاده شد.

سه هایپرپارامتر شامل $n_neighbors$ ، $weights$ و p مورد بررسی قرار گرفتند.

تابع سیگموئید به صورت زیر تعریف می‌شود:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

که در آن:

$$z = w^T x + b$$

است.

از آنجا که رگرسیون لجستیک به مقیاس ویژگی‌ها حساس است، در این پژوهش ویژگی‌ها با استفاده از StandardScaler استانداردسازی شدند.

برای انتخاب بهترین تنظیمات، از Grid Search به همراه Stratified K-Fold Cross Validation استفاده شد.

دو هاپرپارامتر C و class_weight مورد بررسی قرار گرفتند. پارامتر C میزان معکوس قدرت منظم‌سازی مدل را مشخص می‌کند. مقدار کوچک‌تر برای C به معنای منظم‌سازی قوی‌تر و مقدار بزرگ‌تر آن به معنای منظم‌سازی ضعیف‌تر است. برای این پارامتر مقادیر ۰/۰۱، ۰/۱، ۱ و ۱۰۰ بررسی شدند. در پارامتر class_weight دو مقدار None و balanced بررسی شدند.

در مجموع:

$$10 \times 2 = 5$$

ترکیب مختلف بررسی شد.

برای ارزیابی هر ترکیب از Stratified K-Fold Cross Validation با پنج بخش استفاده شد و معیار انتخاب بهترین ترکیب F1-score بود.

جدول ۸: هاپرپارامترهای انتخاب‌شده برای رگرسیون لجستیک

هایپرپارامتر	مقادیر بررسی‌شده	مقدار انتخاب‌شده
C	۰/۰۱، ۰/۱، ۱، ۱۰، ۱۰۰	۱۰
class_weight	balanced، None	None

در نهایت، ترکیب شامل C=10 و class_weight=None به عنوان بهترین تنظیمات انتخاب شد.

مقدار بهترین F1-score در فرآیند اعتبارسنجی برابر با ۰/۷۱۱۸ به دست آمد.

پس از انتخاب هاپرپارامترها، مدل نهایی با استفاده از داده‌های آموزشی استاندارد شده آموزش داده شد و روی مجموعه آزمون ارزیابی گردید.

جدول ۹: نتایج رگرسیون لجستیک روی مجموعه آزمون

Support	-scoreF	Recall	Precision	کلاس
۵۶۶۵۱	۱/۰۰	۱/۰۰	۱/۰۰	۰
۹۵	۰/۶۹	۰/۵۸	۰/۸۵	۱
۵۶۷۴۶	۰/۸۴	۰/۷۹	۰/۹۲	Avg Macro
۵۶۷۴۶	۱/۰۰	۱/۰۰	۱/۰۰	Avg Weighted

بر اساس نتایج، رگرسیون لجستیک برای کلاس اقلیت دارای Precision برابر با ۰/۸۵ و Recall برابر با ۰/۵۸ است.

مقدار F1-score برای کلاس تقلب برابر با ۰/۶۹ به دست آمده است. این نتیجه نشان می‌دهد که در این مجموعه داده، رگرسیون لجستیک نسبت به مدل‌های غیرخطی مانند درخت تصمیم و KNN عملکرد ضعیف‌تری در تشخیص کلاس اقلیت داشته است.

۴.۴. جمع‌بندی مدل‌های پایه

در مرحله اول، سه مدل پایه شامل درخت تصمیم، KNN و رگرسیون لجستیک مورد بررسی قرار گرفتند. برای انتخاب هاپرپارامترهای مناسب هر مدل، از Grid Search همراه با Stratified K-Fold با پنج بخش و معیار F1-score استفاده شد.

نتایج نشان داد که KNN با مقدار F1-score برابر با ۰/۸۲، بهترین عملکرد را در میان مدل‌های پایه داشته است. این مدل با تنظیمات $K = 3$ ، وزندهی distance و فاصله Manhattan به Precision برابر با ۰/۹۶ و Recall برابر با ۰/۷۲ برای کلاس تقلب دست یافت.

درخت تصمیم با Precision برابر با ۰/۹۲، Recall برابر با ۰/۷۱ و F1-score برابر با ۰/۸۰ عملکرد نزدیکی به KNN داشت. در مقابل، رگرسیون لجستیک با Precision برابر با ۰/۸۵، Recall برابر با ۰/۵۸ و F1-score برابر با ۰/۶۹ ضعیف‌ترین عملکرد را در تشخیص کلاس تقلب نشان داد.

بنابراین، در میان مدل‌های پایه، KNN بهترین و رگرسیون لجستیک ضعیف‌ترین عملکرد را داشته است. همچنین مشاهده می‌شود که با وجود Accuracy بسیار بالا در هر سه مدل، معیارهای مربوط به کلاس اقلیت تفاوت قابل توجهی دارند. بنابراین در این مسئله، Precision، Recall و F1-score معیارهای مناسب‌تری برای مقایسه مدل‌ها هستند.

بنابراین، با توجه به محدودیت عملکرد مدل‌های پایه و ماهیت غیرخطی و نامتوازن داده‌ها، استفاده از مدل‌های قدرتمندتر و پیچیده‌تر مانند XGBoost و Forest Random مورد توجه قرار گرفت. هدف از این مرحله، بررسی امکان دستیابی به عملکرد بهتر در شناسایی کلاس اقلیت و در نهایت استفاده از این مدل‌ها در روش Ensemble بود.

۵. مدل‌های پیشرفته

پس از بررسی مدل‌های پایه، مدل‌های قدرتمندتر مبتنی بر درخت تصمیم بررسی شدند. در این مرحله مدل‌های زیر مورد استفاده قرار گرفتند:

• XGBoost

• Forest Random

• KNN

KNN نیز به عنوان یکی از مدل‌های مورد استفاده در Ensemble حفظ شد تا امکان بررسی ترکیب آن با مدل‌های درختی فراهم شود.

۱.۵. جنگل تصادفی

جنگل تصادفی از تعداد زیادی درخت تصمیم تشکیل شده است. هر درخت روی نمونه‌ها و ویژگی‌های متفاوتی آموزش داده می‌شود و در نهایت خروجی درخت‌ها با یکدیگر ترکیب می‌شوند. احتمال تعلق یک نمونه به کلاس تقلب را می‌توان به صورت زیر در نظر گرفت:

$$P(y = 1|x) = \frac{1}{T} \sum_{t=1}^T P_t(y = 1|x)$$

که در آن T تعداد درخت‌ها است.

مزیت مهم جنگل تصادفی کاهش واریانس و کاهش احتمال بیش‌برازش نسبت به یک درخت تصمیم منفرد است.

در این پژوهش پارامترهایی مانند تعداد درخت‌ها، max_depth، min_samples_split و min_samples_leaf مورد بررسی قرار گرفتند.

برای انتخاب تنظیمات مناسب، از Cross-K-Fold Stratified Validation و معیار scoreF استفاده شد.

۲.۵. XGBoost

XGBoost یکی از الگوریتم‌های قدرتمند مبتنی بر روش Gradient Boosting است که از مجموعه‌ای از درخت‌های تصمیم برای ایجاد یک مدل نهایی استفاده می‌کند.

برخلاف روش‌هایی مانند جنگل تصادفی که درخت‌ها را به صورت مستقل آموزش می‌دهند، در XGBoost درخت‌ها به صورت ترتیبی ساخته می‌شوند. هر درخت جدید تلاش می‌کند خطاهای مدل‌های قبلی را کاهش دهد. تابع کلی مدل XGBoost را می‌توان به صورت زیر نمایش داد:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i)$$

که در آن K تعداد درخت‌های موجود در مدل و f_k تابع مربوط به درخت تصمیم k -ام است. تابع هدف XGBoost شامل تابع خطا و جمله منظم‌سازی است:

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

وجود جمله منظم‌سازی به کنترل پیچیدگی مدل و کاهش احتمال بیش‌برازش کمک می‌کند. از پارامترهای مهم XGBoost می‌توان به تعداد درخت‌ها ($n_estimators$)، عمق درخت (max_depth) و نرخ یادگیری ($learning_rate$) اشاره کرد. از آنجا که مجموعه داده دارای عدم توازن شدید بین کلاس سالم و تقلبی است، از پارامتر $scale_pos_weight$ نیز استفاده شد. مقدار این پارامتر به صورت زیر تعیین شد:

$$scale_pos_weight = \frac{N_0}{N_1}$$

که در آن N_0 تعداد نمونه‌های سالم و N_1 تعداد نمونه‌های تقلبی است.

۶. عدم توازن کلاس‌ها

در مسئله تشخیص تقلب، تعداد نمونه‌های کلاس تقلب معمولاً بسیار کمتر از نمونه‌های سالم است. فرض کنیم:

$$N_0 \gg N_1$$

در چنین شرایطی، یک مدل ممکن است تقریباً تمام نمونه‌ها را سالم پیش‌بینی کند و همچنان Accuracy بسیار بالایی به دست آورد.

بنابراین معیارهای دیگری مانند Precision، Recall و F1-score اهمیت بیشتری پیدا می‌کنند. Precision به صورت زیر تعریف می‌شود:

$$Precision = \frac{TP}{TP + FP}$$

Recall نیز برابر است با:

$$Recall = \frac{TP}{TP + FN}$$

و F1-score به صورت زیر محاسبه می‌شود:

$$F1 = 2 \frac{Precision \times Recall}{Precision + Recall}$$

۷. اعتبارسنجی و بهینه‌سازی

برای جلوگیری از وابستگی بیش از حد انتخاب مدل به یک مجموعه Validation، از Cross-Validation K-Fold Stratified استفاده شد.

در این روش داده‌های آموزشی به پنج بخش تقسیم می‌شوند و مدل در پنج مرحله آموزش داده می‌شود. در هر مرحله، چهار بخش برای آموزش و یک بخش برای اعتبارسنجی استفاده می‌شود. همچنین برای انتخاب هایپرپارامترهای مناسب برخی مدل‌ها از Search Grid استفاده شد.

معیار اصلی انتخاب مدل scoreF - در نظر گرفته شد؛ زیرا این معیار تعادل میان Precision و Recall را در نظر می‌گیرد.

$$\theta^* = \arg \max_{\theta \in \Theta} F1(\theta)$$

۸. روش Ensemble

پس از بررسی مدل‌های مختلف، برای بهبود عملکرد از ترکیب XGBoost، Forest Random و KNN استفاده شد.

برای هر نمونه، هر مدل احتمال تعلق نمونه به کلاس تقلب را تولید می‌کند. سپس این احتمالات با وزن‌های مختلف ترکیب می‌شوند:

$$P_{ensemble} = w_{XGB} P_{XGB} + w_{RF} P_{RF} + w_{KNN} P_{KNN}$$

به طوری که:

$$w_{XGB} + w_{RF} + w_{KNN} = 1$$

در این پژوهش وزن‌های مختلف بررسی شدند و بهترین ترکیب بر اساس معیارهای ارزیابی انتخاب شد.

۱.۸. Predictions Out-of-Fold

برای انتخاب وزن‌های Ensemble از Predictions Out-of-Fold استفاده شد.

در روش پنج‌گانه Cross-Validation، در هر مرحله مدل روی چهار Fold آموزش داده شده و روی Fold باقی‌مانده پیش‌بینی می‌کند.

در نتیجه برای هر نمونه یک پیش‌بینی وجود خواهد داشت که مدل تولیدکننده آن نمونه را در فرآیند آموزش خود مشاهده نکرده است.

این پیش‌بینی‌ها برای مدل‌های مورد استفاده ذخیره شدند:

$$P_{XGB}^{OOOF}, \quad P_{RF}^{OOOF}, \quad P_{KNN}^{OOOF}$$

سپس از این پیش‌بینی‌ها برای انتخاب وزن مناسب مدل‌ها استفاده شد.

۲.۸. انتخاب آستانه

پس از ترکیب احتمال مدل‌ها، برای تبدیل احتمال نهایی به برچسب کلاس از یک آستانه استفاده می‌شود:

$$\hat{y} = \begin{cases} 1 & P_{ensemble} \geq \tau \\ 0 & P_{ensemble} < \tau \end{cases}$$

تغییر مقدار τ باعث تغییر در Precision و Recall می‌شود. در این پژوهش هدف انتخاب آستانه‌ای است که:

$$Precision \geq 0.90$$

$$Recall \geq 0.80$$

Value	Parameter
–	Weight XGBoost
–	Weight Forest Random
–	Weight KNN
–	Threshold
–	Precision
–	Recall
–	-scoreIF
–	PR-AUC

جدول ۱۲: نتایج Ensemble نهایی

۱۱. بحث

نتایج نشان می‌دهد که ارزیابی مدل در مسائل نامتوازن باید فراتر از Accuracy انجام شود. در این مسئله، Precision و Recall هر دو اهمیت دارند. Pre-cision بالا باعث کاهش تعداد تراکنش‌های سالمی می‌شود که به اشتباه به عنوان تقلب شناسایی شده‌اند. از طرف دیگر، Recall بالا باعث می‌شود تعداد بیشتری از تراکنش‌های تقلبی شناسایی شوند. به همین دلیل، در مرحله Ensemble هدف تنها افزایش Re-call نبوده است، بلکه تلاش شده است Precision نیز در سطح مناسبی حفظ شود. استفاده از Predictions Out-of-Fold باعث می‌شود انتخاب وزن‌های Ensemble و آستانه تصمیم بر اساس پیش‌بینی‌هایی انجام شود که مدل مربوطه نمونه مورد نظر را در زمان آموزش مشاهده نکرده است.

۱۲. نتیجه‌گیری

در این گزارش، مسئله تشخیص تراکنش‌های تقلبی با استفاده از روش‌های مختلف یادگیری ماشین بررسی شد. در مرحله اول، مدل‌های پایه شامل درخت تصمیم، KNN و رگرسیون لجستیک مورد بررسی قرار گرفتند. در مرحله بعد، مدل‌های پیشرفته‌تر شامل XGBoost و Random Forest مورد استفاده قرار گرفتند. در نهایت، XGBoost، Forest Random و KNN در قالب یک روش Ensemble ترکیب شدند. برای انتخاب وزن مدل‌ها از Predictions Out-of-Fold حاصل از Cross-Validation K-Fold Stratified استفاده شد. همچنین Threshold تصمیم به عنوان یکی از پارامترهای مهم سیستم بررسی شد؛ زیرا تغییر آن می‌تواند تعادل میان Precision و Recall را تغییر دهد. هدف نهایی انتخاب ترکیبی بود که Precision حداقل ۹۰ درصد و Recall حداقل ۸۰ درصد داشته باشد و در میان ترکیب‌های مجاز، بیشترین -scoreIF را ایجاد کند.

مراجع

- [۱] Breiman, L. "Random Forests," *Machine Learning*, ۲۰۰۱.
- [۲] Guestrin, C. and Chen T. "XGBoost: Scalable Tree Boosting," *Proceedings of the ACM SIGKDD*, ۲۰۱۶.
- [۳] Han, J. and Kamber M. "Data Mining: Concepts and Techniques," ۲۰۱۱.

باشد.

در میان ترکیب‌هایی که این دو شرط را برآورده می‌کنند، ترکیبی انتخاب می‌شود که بیشترین -scoreIF را داشته باشد.

۹. ارزیابی مدل‌ها

برای مقایسه مدل‌ها از ماتریس درهم‌ریختگی و معیارهای Pre-cision، Recall، -scoreIF و PR-AUC استفاده می‌شود. ماتریس درهم‌ریختگی به شکل زیر است:

$$\begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$$

در مسئله تشخیص تقلب، مقدار FN اهمیت زیادی دارد؛ زیرا هر FN نشان‌دهنده یک تراکنش تقلبی است که توسط مدل به عنوان تراکنش سالم شناسایی شده است. از طرف دیگر، مقدار FP نیز نشان‌دهنده تراکنش سالمی است که به اشتباه به عنوان تقلب شناسایی شده است. بنابراین در این پژوهش تلاش می‌شود میان Precision و Re-call تعادل مناسبی ایجاد شود.

۱۰. نتایج

در این بخش نتایج حاصل از اجرای مدل‌های مختلف بررسی می‌شوند.

۱۰.۱. نتایج مدل‌های پایه

در مرحله اول، عملکرد مدل‌های پایه شامل درخت تصمیم، KNN و رگرسیون لجستیک بررسی شد.

Model	Precision	Recall	IF	PR-AUC
Tree Decision	–	–	–	–
KNN	–	–	–	–
Regression Logistic	–	–	–	–

جدول ۱۰: نتایج مدل‌های پایه

۱۰.۲. نتایج مدل‌های پیشرفته

در مرحله بعد، مدل‌های XGBoost و Forest Random بررسی شدند. همچنین KNN به عنوان یکی از مدل‌های مورد استفاده در Ensemble حفظ شد.

Model	Precision	Recall	IF	PR-AUC
XGBoost	–	–	–	–
Forest Random	–	–	–	–
KNN	–	–	–	–

جدول ۱۱: نتایج مدل‌های پیشرفته

۱۰.۳. نتایج Ensemble

در مرحله نهایی، احتمال‌های تولیدشده توسط XGBoost، Forest Random و KNN با وزن‌های بهینه ترکیب شدند. وزن‌ها و آستانه نهایی با استفاده از پیش‌بینی‌های Out-of-Fold انتخاب شدند. هدف انتخاب ترکیبی بود که Precision حداقل ۹۰ درصد و Recall حداقل ۸۰ درصد داشته باشد و در میان این ترکیب‌ها بیشترین -scoreIF را ایجاد کند.