

گزارش علمی

بررسی روش‌های یادگیری ماشین
در تشخیص تقلب مالی

نام نویسنده: امیر

دانشگاه / دانشکده

۴. روش‌های یادگیری ماشین

در این پژوهش چند الگوریتم مختلف برای تشخیص تراکنش‌های تقلبی بررسی شده‌اند.

۱.۴. درخت تصمیم

درخت تصمیم داده‌ها را با استفاده از مجموعه‌ای از قوانین شرطی به بخش‌های مختلف تقسیم می‌کند. هدف الگوریتم ایجاد تقسیم‌هایی است که نمونه‌های متعلق به کلاس‌های مختلف را تا حد امکان از یکدیگر جدا کنند. یکی از پارامترهای مهم درخت تصمیم، عمق درخت است. افزایش بیش از حد عمق می‌تواند باعث بیش‌برازش شود. برای انتخاب عمق مناسب می‌توان از اعتبارسنجی متقابل K-Fold Stratified استفاده کرد.

۲.۴. جنگل تصادفی

جنگل تصادفی از تعداد زیادی درخت تصمیم تشکیل شده است. هر درخت روی نمونه‌ها و ویژگی‌های متفاوتی آموزش داده می‌شود و در نهایت خروجی درخت‌ها با یکدیگر ترکیب می‌شوند. احتمال تعلق یک نمونه به کلاس تقلب را می‌توان به صورت زیر در نظر گرفت:

$$P(y=1|x) = \frac{1}{T} \sum_{t=1}^T P_t(y=1|x)$$

که در آن T تعداد درخت‌ها است. مزیت مهم جنگل تصادفی کاهش واریانس و کاهش احتمال بیش‌برازش نسبت به یک درخت تصمیم منفرد است.

۲.۲. XGBoost

XGBoost یک الگوریتم مبتنی بر روش Boosting است که درخت‌ها را به صورت ترتیبی آموزش می‌دهد. هر درخت جدید تلاش می‌کند خطاهای مدل‌های قبلی را کاهش دهد. تابع کلی مدل را می‌توان به صورت زیر نمایش داد:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i)$$

که در آن f_k درخت تصمیم k -ام است. در مسائل نامتوازن می‌توان با استفاده از پارامترهایی مانند `scale_pos_weight` اهمیت کلاس اقلیت را افزایش داد.

۵. عدم توازن کلاس‌ها

در مسئله تشخیص تقلب، تعداد نمونه‌های کلاس تقلب معمولاً بسیار کمتر از نمونه‌های سالم است. فرض کنیم:

$$N_0 \gg N_1$$

که در آن N_0 تعداد نمونه‌های سالم و N_1 تعداد نمونه‌های تقلبی است. در چنین شرایطی، یک مدل ممکن است تقریباً تمام نمونه‌ها را سالم پیش‌بینی کند و همچنان Accuracy بسیار بالایی به دست آورد. بنابراین معیارهای دیگری مانند Recall Precision و F1-score اهمیت بیشتری پیدا می‌کنند.

چکیده

تشخیص تراکنش‌های مالی تقلبی یکی از مسائل مهم در حوزه یادگیری ماشین است. نامتوازن بودن داده‌ها، تعداد بسیار کم نمونه‌های تقلبی و هزینه بالای تشخیص نادرست از جمله چالش‌های اصلی این مسئله هستند. در این گزارش، چندین الگوریتم یادگیری ماشین شامل درخت تصمیم، جنگل تصادفی و XGBoost بررسی شده و عملکرد آن‌ها با استفاده از معیارهایی مانند Re-Precision، F1-score call و PR-AUC ارزیابی می‌شود. همچنین استفاده از روش‌های Ensemble برای ترکیب چند مدل و بهبود عملکرد سیستم مورد بررسی قرار می‌گیرد. **واژگان کلیدی:** یادگیری ماشین، تشخیص تقلب، تراکنش مالی، جنگل تصادفی، XGBoost، Ensemble، داده‌های نامتوازن

۱. مقدمه

افزایش استفاده از سامانه‌های پرداخت الکترونیکی باعث شده است که حجم بسیار زیادی از تراکنش‌های مالی در هر روز ثبت شود. در کنار این افزایش، احتمال وقوع تراکنش‌های تقلبی نیز وجود دارد. تشخیص خودکار تراکنش‌های تقلبی می‌تواند نقش مهمی در کاهش خسارت‌های مالی داشته باشد. با این حال، مسئله تشخیص تقلب معمولاً با یک مشکل مهم یعنی نامتوازن بودن کلاس‌ها مواجه است. در بسیاری از مجموعه‌داده‌های واقعی، تعداد تراکنش‌های سالم بسیار بیشتر از تراکنش‌های تقلبی است. بنابراین یک مدل ممکن است دقت بسیار بالایی داشته باشد، اما در تشخیص نمونه‌های تقلبی عملکرد مناسبی نداشته باشد. به همین دلیل، در این مسئله معیارهایی مانند Recall و PR-AUC اهمیت زیادی پیدا می‌کنند.

۲. معرفی داده‌ها

در این پژوهش از یک مجموعه‌داده شامل تراکنش‌های مالی استفاده شده است. هر نمونه شامل تعدادی ویژگی مربوط به تراکنش و یک برچسب دودویی است. برچسب صفر نشان‌دهنده تراکنش سالم و برچسب یک نشان‌دهنده تراکنش تقلبی است. یکی از ویژگی‌های مهم داده، عدم توازن شدید بین دو کلاس است. به همین دلیل، استفاده از Accuracy به‌تنهایی نمی‌تواند معیار مناسبی برای ارزیابی مدل باشد. داده‌ها پس از انجام مراحل پیش‌پردازش به دو مجموعه آموزش و آزمون تقسیم شدند.

۳. پیش‌پردازش داده‌ها

همانطور که بررسی کردیم، جدول ما دارای مقادیر تکراری می‌باشد و راه حلی که استفاده کردم حذف این مقادیر تکراری بود. داده‌ها به دو مجموعه آموزش و آزمون تقسیم شدند:

$$D = D_{\text{train}} \cup D_{\text{test}}$$

به‌طوری‌که مجموعه آزمون در فرآیند آموزش مدل استفاده

۹. بحث

نتایج نشان می‌دهد که ارزیابی مدل در مسائل نامتوازن باید فراتر از Accuracy انجام شود. در این مسئله، افزایش Recall می‌تواند به معنای شناسایی تعداد بیشتری از تراکنش‌های تقلبی باشد، هرچند ممکن است باعث افزایش تعداد مثبت‌های کاذب شود. از طرف دیگر، افزایش بیش از حد Recall ممکن است Precision را کاهش دهد. بنابراین انتخاب آستانه مناسب اهمیت زیادی دارد. همچنین استفاده از Ensemble می‌تواند با ترکیب نقاط قوت مدل‌های مختلف، عملکرد کلی سیستم را بهبود دهد.

۱۰. نتیجه‌گیری

در این گزارش، مسئله تشخیص تراکنش‌های تقلبی با استفاده از روش‌های مختلف یادگیری ماشین بررسی شد. مدل‌های درخت تصمیم، جنگل تصادفی و XGBoost از جمله روش‌های مورد بررسی بودند. نتایج نشان می‌دهد که در داده‌های نامتوازن، معیارهایی مانند Recall و PR-AUC برای ارزیابی مدل اهمیت ویژه‌ای دارند. همچنین ترکیب مدل‌های مختلف در قالب روش‌های Ensemble می‌تواند راهکاری مناسب برای افزایش توانایی سیستم در تشخیص نمونه‌های تقلبی باشد. در ادامه می‌توان با بهینه‌سازی هایپارامترها، انتخاب آستانه مناسب و استفاده از روش‌های پیشرفته‌تر Ensemble، عملکرد سیستم را بهبود داد.

مراجع

- [۱] "Random Breiman, L. Learning, Machine Forests," ۲۰۰۱.
- [۲] Tree Scalable A "XGBoost: Guestrin, C. and Chen T. ACM ۲۲nd the of Proceedings System," Boosting ۲۰۱۶ SIGKDD.
- [۳] Con- Mining: Data Pei, J. and Kamber M. Han, J. Techniques. and cepts

Precision به صورت زیر تعریف می‌شود:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall نیز برابر است با:

$$\text{Recall} = \frac{TP}{TP + FN}$$

و F1-score به صورت زیر محاسبه می‌شود:

$$F1 = 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

۶. ارزیابی مدل‌ها

برای مقایسه مدل‌ها از ماتریس درهم‌ریختگی و معیارهای Precision، Recall، F1-score و PR-AUC استفاده می‌شود. ماتریس درهم‌ریختگی به شکل زیر است:

$$\begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$$

در مسئله تشخیص تقلب، مقدار FN اهمیت زیادی دارد؛ زیرا هر FN نشان‌دهنده یک تراکنش تقلبی است که توسط مدل به عنوان تراکنش سالم شناسایی شده است. بنابراین در بسیاری از کاربردهای تشخیص تقلب، افزایش Recall می‌تواند یکی از اهداف اصلی بهینه‌سازی مدل باشد.

۷. روش Ensemble

برای بهبود عملکرد می‌توان خروجی چند مدل را با یکدیگر ترکیب کرد. برای مثال، احتمال تقلب حاصل از سه مدل را می‌توان به شکل زیر ترکیب کرد:

$$P_{\text{ensemble}} = w_1 P_{\text{DT}} + w_2 P_{\text{RF}} + w_3 P_{\text{XGB}}$$

به‌طوری‌که:

$$w_1 + w_2 + w_3 = 1$$

برای مثال می‌توان از ترکیب زیر استفاده کرد:

$$P_{\text{ensemble}} = 0.2 P_{\text{DT}} + 0.4 P_{\text{RF}} + 0.4 P_{\text{XGB}}$$

پس از محاسبه احتمال نهایی، می‌توان با استفاده از یک آستانه مناسب کلاس نهایی را تعیین کرد:

$$\hat{y} = \begin{cases} 1 & P_{\text{ensemble}} \geq \tau \\ 0 & P_{\text{ensemble}} < \tau \end{cases}$$

انتخاب مقدار τ تأثیر مستقیمی بر Precision و Recall مدل دارد.

۸. نتایج

در این بخش نتایج حاصل از اجرای مدل‌های مختلف یادگیری ماشین بررسی می‌شوند. معیارهای اصلی مورد استفاده شامل Recall، Precision، F1-score و PR-AUC هستند. در مسئله تشخیص تقلب، معیار Recall اهمیت ویژه‌ای دارد؛ زیرا نشان می‌دهد چه نسبتی از تراکنش‌های تقلبی واقعاً توسط مدل شناسایی شده‌اند. همچنین می‌توان عملکرد مدل‌ها را با استفاده از ماتریس درهم‌ریختگی بررسی کرد. نتایج به دست آمده برای هر مدل باید بر اساس داده‌های واقعی آزمایش ثبت و مقایسه شوند.