

بررسی روش‌های یادگیری ماشین در تشخیص تقلب مالی

نام نویسنده: امیرحسین رنجبر

چکیده

تشخیص تراکنش‌های مالی تقلبی یکی از مسائل مهم در حوزه یادگیری ماشین است. نامتوازن بودن داده‌ها، تعداد بسیار کم نمونه‌های تقلبی و هزینه بالای تشخیص نادرست از جمله چالش‌های اصلی این مسئله هستند.

در این گزارش، ابتدا چند مدل پایه شامل درخت تصمیم، KNN و رگرسیون لجستیک بررسی می‌شوند. سپس مدل‌های پیشرفته‌تر شامل XGBoost و جنگل تصادفی مورد بررسی قرار می‌گیرند. همچنین مدل‌های مختلف در یک روش Ensemble ترکیب می‌شوند.

عملکرد مدل‌ها با استفاده از معیارهایی مانند Precision، Recall، F1-score و PR-AUC ارزیابی می‌شود. همچنین برای انتخاب تنظیمات مناسب مدل‌ها از روش‌های اعتبارسنجی متقابل و بهینه‌سازی هایپرپارامترها استفاده می‌شود.

واژگان کلیدی:

یادگیری ماشین، تشخیص تقلب، تراکنش مالی، درخت تصمیم، KNN، رگرسیون لجستیک، جنگل تصادفی، Ensem- XGBoost، ble، داده‌های نامتوازن

۱. مقدمه

افزایش استفاده از سامانه‌های پرداخت الکترونیکی باعث شده است که حجم بسیار زیادی از تراکنش‌های مالی در هر روز ثبت شود. در کنار این افزایش، احتمال وقوع تراکنش‌های تقلبی نیز وجود دارد. تشخیص خودکار تراکنش‌های تقلبی می‌تواند نقش مهمی در کاهش خسارت‌های مالی داشته باشد. با این حال، مسئله تشخیص تقلب معمولاً با مشکل نامتوازن بودن کلاس‌ها مواجه است.

در بسیاری از مجموعه‌داده‌های واقعی، تعداد تراکنش‌های سالم بسیار بیشتر از تراکنش‌های تقلبی است. بنابراین یک مدل ممکن است دقت بسیار بالایی داشته باشد، اما در تشخیص نمونه‌های تقلبی عملکرد مناسبی نداشته باشد.

به همین دلیل، در این مسئله معیارهایی مانند Precision، Recall، F1-score و PR-AUC اهمیت زیادی پیدا می‌کنند.

در این پژوهش، ابتدا مدل‌های پایه بررسی شده و سپس مدل‌های پیشرفته‌تر و در نهایت روش Ensemble مورد استفاده قرار گرفته‌اند.

۲. معرفی داده‌ها

در این پژوهش از یک مجموعه‌داده شامل تراکنش‌های مالی استفاده شده است. هر نمونه شامل تعدادی ویژگی مربوط به تراکنش و یک برچسب دودویی است.

برچسب صفر نشان‌دهنده تراکنش سالم و برچسب یک نشان‌دهنده تراکنش تقلبی است.

یکی از ویژگی‌های مهم داده، عدم توازن شدید بین دو کلاس است. به همین دلیل، استفاده از Accuracy به‌تنهایی نمی‌تواند معیار مناسبی برای ارزیابی مدل باشد.

داده‌ها پس از انجام مراحل پیش‌پردازش به دو مجموعه آموزش و آزمون تقسیم شدند.

۳. پیش‌پردازش داده‌ها

پیش از آموزش مدل‌ها، داده‌ها بررسی و آماده‌سازی شدند. مراحل پیش‌پردازش شامل بررسی مقادیر گمشده، داده‌های تکراری و آماده‌سازی ویژگی‌ها برای ورود به مدل است.

همان‌طور که در بررسی اولیه داده‌ها مشاهده شد، مجموعه‌داده دارای تعدادی مقدار تکراری بود. از آنجا که وجود داده‌های تکراری می‌تواند بر فرآیند آموزش مدل تأثیر بگذارد، این نمونه‌ها شناسایی و حذف شدند. تعداد نمونه‌ها و تراکنش‌های تقلبی قبل و بعد از حذف داده‌های تکراری در جدول زیر ارائه شده است.

جدول ۱: مقایسه داده‌ها قبل و بعد از حذف نمونه‌های تکراری

After	Before	Data
۲۸۴۳۱۵	۲۸۴۸۰۷	transactions Total
۴۷۳	۴۹۲	transactions Fraudulent

همان‌طور که مشاهده می‌شود، تعداد کل تراکنش‌ها از ۲۸۴۸۰۷ به ۲۸۴۳۱۵ کاهش یافته است. همچنین تعداد تراکنش‌های تقلبی از ۴۹۲ نمونه به ۴۷۳ نمونه رسیده است. داده‌ها به دو مجموعه آموزش و آزمون تقسیم شدند:

$$D = D_{\text{train}} \cup D_{\text{test}}$$

به‌طوری‌که مجموعه آزمون در فرآیند آموزش مدل استفاده نمی‌شود.

در صورت وجود ویژگی‌هایی با مقیاس‌های متفاوت، می‌توان از روش‌های استانداردسازی برای آماده‌سازی داده‌ها استفاده کرد. استانداردسازی به‌خصوص برای مدل‌هایی مانند KNN و رگرسیون لجستیک اهمیت دارد.

۴. مدل‌های پایه

در مرحله اول پژوهش، سه مدل پایه برای ایجاد یک معیار اولیه از عملکرد سیستم مورد بررسی قرار گرفتند:

• درخت تصمیم

• KNN

• رگرسیون لجستیک

هدف از استفاده از مدل‌های پایه، بررسی عملکرد الگوریتم‌های مختلف و ایجاد مبنایی برای مقایسه با مدل‌های پیشرفته‌تر است.

۱.۴. درخت تصمیم

درخت تصمیم یکی از الگوریتم‌های یادگیری ماشین است که با تقسیم متوالی داده‌ها بر اساس ویژگی‌های مختلف، ساختاری درختی برای انجام پیش‌بینی ایجاد می‌کند.

پیچیدگی و عملکرد این مدل به هایپرپارامترهای مختلفی وابسته است.

در این آزمایش، سه هایپرپارامتر مهم شامل max_depth، min_samples_split و min_samples_leaf مورد بررسی قرار گرفتند.

هایپرپارامتر max_depth حداکثر عمق درخت را مشخص می‌کند.

افزایش این مقدار امکان ایجاد ساختارهای پیچیده‌تر را فراهم می‌کند، اما افزایش بیش از حد آن می‌تواند باعث بیش‌برازش شود. برای این پارامتر مقادیر ۵، ۸، ۱۰، ۱۵، ۲۰ و None بررسی شدند. پارامتر min_samples_split حداقل تعداد نمونه‌های مورد نیاز برای انجام تقسیم یک گره را مشخص می‌کند. مقادیر ۲، ۵، ۱۰ و ۲۰ برای این پارامتر در نظر گرفته شدند.

پارامتر min_samples_leaf حداقل تعداد نمونه‌هایی را مشخص می‌کند که باید در هر گره برگ قرار داشته باشند. مقادیر ۱، ۲، ۵ و ۱۰ برای این پارامتر بررسی شدند.

برای انتخاب بهترین ترکیب از این هایپرپارامترها، از روش Grid Search استفاده شد.

برای $n_neighbors$ مقادیر ۳، ۵، ۷، ۹، ۱۱، ۱۵، ۲۰، ۲۵ و ۳۰ بررسی شدند.

در پارامتر $weights$ دو حالت $uniform$ و $distance$ بررسی شد. در حالت $distance$ ، نمونه‌های نزدیک‌تر وزن بیشتری در تصمیم‌گیری دارند.

پارامتر p نوع فاصله مورد استفاده را مشخص می‌کند. مقدار $p = 1$ متناظر با فاصله $Manhattan$ و مقدار $p = 2$ متناظر با فاصله $Euclidean$ است. در مجموع:

$$9 \times 2 \times 2 = 36$$

ترکیب مختلف بررسی شد. برای ارزیابی هر ترکیب از Stratified K-Fold Cross Validation با پنج بخش استفاده شد و معیار انتخاب بهترین ترکیب F1-score بود.

جدول ۵: هایپرپارامترهای انتخاب شده برای KNN

هایپرپارامتر	مقادیر بررسی شده	مقدار انتخاب شده
$n_neighbors$	۳، ۵، ۷، ۹، ۱۱، ۱۵، ۲۰، ۲۵، ۳۰	۳
$weights$	$distance$ ، $uniform$	$distance$
p	۱، ۲	۱

در نتیجه، بهترین تنظیمات KNN شامل $K = 3$ ، وزن‌دهی $distance$ و فاصله $Manhattan$ ($p = 1$) بود.

مقدار بهترین F1-score در فرآیند اعتبارسنجی برابر با ۰/۸۵۴۳ به دست آمد.

پس از انتخاب هایپرپارامترها، مدل نهایی با استفاده از داده‌های آموزشی استاندارد شده آموزش داده شد و روی مجموعه آزمون ارزیابی گردید.

جدول ۶: نتایج مدل KNN روی مجموعه آزمون

Support	F1-score	Recall	Precision	کلاس
۵۶۶۵۱	۱/۰۰	۱/۰۰	۱/۰۰	۰
۹۵	۰/۸۲	۰/۷۲	۰/۹۶	۱
۵۶۷۴۶	۰/۹۱	۰/۸۶	۰/۹۸	Avg Macro
۵۶۷۴۶	۱/۰۰	۱/۰۰	۱/۰۰	Avg Weighted

ماتریس درهم‌ریختگی مدل نیز به صورت زیر به دست آمد:

جدول ۷: ماتریس درهم‌ریختگی مدل KNN

پیش‌بینی کلاس ۰	پیش‌بینی کلاس ۱	واقعی کلاس ۰	واقعی کلاس ۱
۵۶۶۴۸	۳	۰	۳
۲۷	۶۸	۰	۶۸

بر اساس نتایج، مدل KNN برای کلاس اقلیت دارای Precision برابر با ۰/۹۶ و Recall برابر با ۰/۷۲ است.

مدل توانسته است ۶۸ مورد از مجموع ۹۵ تراکنش تقلبی را به درستی شناسایی کند، در حالی که ۲۷ نمونه تقلبی از دست رفته‌اند.

همچنین تنها ۳ تراکنش سالم به اشتباه به عنوان تقلب شناسایی شده‌اند. مقدار F1-score برابر با ۰/۸۲ است.

۳.۴. رگرسیون لجستیک

رگرسیون لجستیک یکی از روش‌های کلاسیک برای مسائل طبقه‌بندی دودویی است. این مدل ترکیب خطی ویژگی‌ها را محاسبه کرده و با استفاده از تابع سیگموئید احتمال تعلق نمونه به کلاس مثبت را به دست می‌آورد.

از آنجا که برای سه هایپرپارامتر به ترتیب ۷، ۴ و ۴ مقدار در نظر گرفته شد، در مجموع:

$$7 \times 4 \times 4 = 112$$

ترکیب مختلف مورد بررسی قرار گرفت. برای ارزیابی هر ترکیب از Stratified K-Fold Cross Validation با پنج بخش استفاده شد. معیار F1-score به عنوان معیار انتخاب بهترین ترکیب در نظر گرفته شد.

در نهایت، بهترین ترکیب هایپرپارامترها به صورت زیر به دست آمد:

جدول ۲: هایپرپارامترهای انتخاب شده برای درخت تصمیم

هایپرپارامتر	مقادیر بررسی شده	مقدار انتخاب شده
max_depth	۳، ۵، ۸، ۱۰، ۱۵، ۲۰، $None$	۸
$min_samples_split$	۲، ۵، ۱۰، ۲۰	۲۰
$min_samples_leaf$	۱، ۲، ۵، ۱۰	۵

پس از انتخاب هایپرپارامترها، مدل نهایی با استفاده از داده‌های آموزشی آموزش داده شد و سپس روی مجموعه داده‌های آزمون ارزیابی گردید.

جدول ۳: نتایج مدل درخت تصمیم روی مجموعه آزمون

Support	F1-score	Recall	Precision	کلاس
۵۶۶۵۱	۱/۰۰	۱/۰۰	۱/۰۰	۰
۹۵	۰/۸۰	۰/۷۱	۰/۹۲	۱
۵۶۷۴۶	۰/۹۰	۰/۸۵	۰/۹۶	Avg Macro
۵۶۷۴۶	۱/۰۰	۱/۰۰	۱/۰۰	Avg Weighted

همچنین ماتریس درهم‌ریختگی مدل به صورت زیر به دست آمد:

جدول ۴: ماتریس درهم‌ریختگی مدل درخت تصمیم

پیش‌بینی کلاس ۰	پیش‌بینی کلاس ۱	واقعی کلاس ۰	واقعی کلاس ۱
۵۶۶۴۵	۶	۰	۶
۲۸	۶۷	۰	۶۷

بر اساس نتایج، مدل برای کلاس اقلیت دارای Precision برابر با ۰/۹۲ و Recall برابر با ۰/۷۱ است.

مدل توانسته است ۶۷ مورد از مجموع ۹۵ نمونه مثبت را به درستی شناسایی کند، در حالی که ۲۸ نمونه مثبت به اشتباه به عنوان کلاس ۰ پیش‌بینی شده‌اند.

همچنین تنها ۶ نمونه از کلاس ۰ به اشتباه به عنوان کلاس ۱ شناسایی شده‌اند. مقدار F1-score برابر با ۰/۸۰ است.

۲.۴. K نزدیک‌ترین همسایه

الگوریتم KNN یکی از روش‌های مبتنی بر فاصله است که برای طبقه‌بندی یک نمونه جدید، نزدیک‌ترین نمونه‌های موجود در داده‌های آموزشی را بررسی می‌کند.

پارامتر $n_neighbors$ یا همان K ، تعداد همسایه‌هایی را مشخص می‌کند که در تصمیم‌گیری مورد استفاده قرار می‌گیرند.

از آنجا که KNN بر اساس فاصله بین نمونه‌ها عمل می‌کند، استانداردسازی ویژگی‌ها اهمیت زیادی دارد. در این پژوهش، داده‌های آموزشی پیش از استفاده در KNN استانداردسازی شدند. برای انتخاب بهترین تنظیمات مدل، از Grid Search به همراه Stratified K-Fold Cross Validation استفاده شد.

سه هایپرپارامتر شامل $n_neighbors$ ، $weights$ و p مورد بررسی قرار گرفتند.

تابع سیگموئید به صورت زیر تعریف می‌شود:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

که در آن:

$$z = w^T x + b$$

است.

از آنجا که رگرسیون لجستیک به مقیاس ویژگی‌ها حساس است، در این پژوهش ویژگی‌ها با استفاده از StandardScaler استانداردسازی شدند.

برای انتخاب بهترین تنظیمات، از Grid Search به همراه Stratified K-Fold Cross Validation استفاده شد.

دو هاپرپارامتر $class_weight$ و C مورد بررسی قرار گرفتند. پارامتر C میزان معکوس قدرت منظم‌سازی مدل را مشخص می‌کند.

مقدار کوچک‌تر برای C به معنای منظم‌سازی قوی‌تر و مقدار بزرگ‌تر آن به معنای منظم‌سازی ضعیف‌تر است.

برای این پارامتر مقادیر ۰/۰۱، ۱، ۱۰ و ۱۰۰ بررسی شدند. در پارامتر $class_weight$ دو مقدار None و balanced بررسی شدند.

در مجموع:

$$5 \times 2 = 10$$

ترکیب مختلف بررسی شد.

برای ارزیابی هر ترکیب از Stratified K-Fold Cross Validation با پنج بخش استفاده شد و معیار انتخاب بهترین ترکیب F1-score بود.

جدول ۸: هاپرپارامترهای انتخاب‌شده برای رگرسیون لجستیک

هایپرپارامتر	مقادیر بررسی‌شده	مقدار انتخاب‌شده
C	۰/۰۱، ۱، ۱۰، ۱۰۰	۱۰
class_weight	balanced، None	None

در نهایت، ترکیب شامل $C=10$ و $class_weight=None$ به عنوان بهترین تنظیمات انتخاب شد.

مقدار بهترین F1-score در فرآیند اعتبارسنجی برابر با ۰/۷۱۱۸ به دست آمد.

پس از انتخاب هاپرپارامترها، مدل نهایی با استفاده از داده‌های آموزشی استاندارد شده آموزش داده شد و روی مجموعه آزمون ارزیابی گردید.

جدول ۹: نتایج رگرسیون لجستیک روی مجموعه آزمون

Support	F1-score	Recall	Precision	کلاس
۵۶۶۵۱	۱/۰۰	۱/۰۰	۱/۰۰	۰
۹۵	۰/۶۹	۰/۵۸	۰/۸۵	۱
۵۶۷۴۶	۰/۸۴	۰/۷۹	۰/۹۲	Avg Macro
۵۶۷۴۶	۱/۰۰	۱/۰۰	۱/۰۰	Avg Weighted

بر اساس نتایج، رگرسیون لجستیک برای کلاس اقلیت دارای Precision برابر با ۰/۸۵ و Recall برابر با ۰/۵۸ است.

مقدار F1-score برای کلاس تقلب برابر با ۰/۶۹ به دست آمده است. این نتیجه نشان می‌دهد که در این مجموعه داده، رگرسیون لجستیک نسبت به مدل‌های غیرخطی مانند درخت تصمیم و KNN عملکرد ضعیف‌تری در تشخیص کلاس اقلیت داشته است.

۴.۴. جمع‌بندی مدل‌های پایه

در مرحله اول، سه مدل پایه شامل درخت تصمیم، KNN و رگرسیون لجستیک مورد بررسی قرار گرفتند. برای انتخاب هاپرپارامترهای مناسب هر مدل، از Grid Search همراه با Stratified K-Fold با پنج بخش و معیار F1-score استفاده شد.

نتایج نشان داد که KNN با مقدار F1-score برابر با ۰/۸۲، بهترین عملکرد را در میان مدل‌های پایه داشته است. این مدل با تنظیمات $K=3$ ، وزن‌دهی distance و فاصله Manhattan به Precision برابر با ۰/۹۶ و Recall برابر با ۰/۷۲ برای کلاس تقلب دست یافت.

درخت تصمیم با Precision برابر با ۰/۹۲، Recall برابر با ۰/۷۱ و F1-score برابر با ۰/۸۰ عملکرد نزدیکی به KNN داشت.

در مقابل، رگرسیون لجستیک با Precision برابر با ۰/۸۵، Recall برابر با ۰/۵۸ و F1-score برابر با ۰/۶۹ ضعیف‌ترین عملکرد را در تشخیص کلاس تقلب نشان داد.

بنابراین، در میان مدل‌های پایه، KNN بهترین و رگرسیون لجستیک ضعیف‌ترین عملکرد را داشته است. همچنین مشاهده می‌شود که با وجود Accuracy بسیار بالا در هر سه مدل، معیارهای مربوط به کلاس اقلیت تفاوت قابل توجهی دارند. بنابراین در این مسئله، Precision، Recall و F1-score معیارهای مناسب‌تری برای مقایسه مدل‌ها هستند.

بنابراین، با توجه به محدودیت عملکرد مدل‌های پایه و ماهیت غیرخطی و نامتوازن داده‌ها، استفاده از مدل‌های قدرتمندتر و پیچیده‌تر مانند XGBoost و Forest Random مورد توجه قرار گرفت.

هدف از این مرحله، بررسی امکان دستیابی به عملکرد بهتر در شناسایی کلاس اقلیت و در نهایت استفاده از این مدل‌ها در روش Ensemble بود.

۵. مدل‌های پیشرفته

پس از بررسی مدل‌های پایه، مدل‌های قدرتمندتر مبتنی بر درخت تصمیم بررسی شدند.

در این مرحله مدل‌های زیر مورد استفاده قرار گرفتند:

• XGBoost

• Forest Random

• KNN

KNN نیز به عنوان یکی از مدل‌های مورد استفاده در Ensemble حفظ شد تا امکان بررسی ترکیب آن با مدل‌های درختی فراهم شود.

۱.۵. XGBoost

XGBoost یکی از الگوریتم‌های قدرتمند مبتنی بر روش Gradient Boosting است که از مجموعه‌ای از درخت‌های تصمیم برای ایجاد یک مدل نهایی استفاده می‌کند.

برخلاف روش‌هایی مانند جنگل تصادفی که درخت‌ها را به صورت مستقل آموزش می‌دهند، در XGBoost درخت‌ها به صورت ترتیبی ساخته می‌شوند. هر درخت جدید تلاش می‌کند خطاهای مدل‌های قبلی را کاهش دهد.

تابع کلی مدل XGBoost را می‌توان به صورت زیر نمایش داد:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i)$$

که در آن K تعداد درخت‌های موجود در مدل و f_k تابع مربوط به درخت تصمیم k -ام است.

تابع هدف XGBoost شامل تابع خطا و جمله منظم‌سازی است:

پس از انتخاب بهترین هایپرپارامترها، مدل نهایی با استفاده از تمام داده‌های آموزشی آموزش داده شد و سپس روی مجموعه آزمون ارزیابی گردید.

جدول ۱۱: نتایج مدل XGBoost روی مجموعه آزمون

Support	F1-score	Recall	Precision	کلاس
۵۶۶۵۱	۱/۰۰	۱/۰۰	۱/۰۰	۰
۹۵	۰/۸۵	۰/۷۹	۰/۹۳	۱
۵۶۷۴۶	۰/۹۳	۰/۸۹	۰/۹۶	Avg Macro
۵۶۷۴۶	۱/۰۰	۱/۰۰	۱/۰۰	Avg Weighted

بر اساس نتایج، XGBoost برای کلاس اقلیت دارای Precision برابر با ۰/۹۳، Recall برابر با ۰/۷۹ و F1-score برابر با ۰/۸۵ است. بنابراین مدل توانسته است حدود ۷۹ درصد از تراکنش‌های تقلبی موجود در مجموعه آزمون را شناسایی کند. همچنین مقدار Precision برابر با ۰/۹۳ نشان می‌دهد که بخش عمده تراکنش‌هایی که توسط مدل به عنوان تقلب شناسایی شده‌اند، واقعاً تقلبی بوده‌اند. مقدار F1-score برابر با ۰/۸۵ نیز نشان‌دهنده تعادل مناسب میان Precision و Recall در تشخیص کلاس تقلب است. با توجه به اینکه معیار انتخاب مدل در فرآیند Grid Search، مقدار F1-score بوده است، نتیجه اعتبارسنجی ۰/۸۶۳۹ و نتیجه آزمون ۰/۸۵ به دست آمده است. نزدیک بودن این دو مقدار نشان می‌دهد که افت عملکرد مدل از مرحله اعتبارسنجی به مجموعه آزمون نسبتاً محدود بوده است. در مقایسه با مدل‌های پایه، XGBoost عملکرد بهتری در تشخیص کلاس اقلیت نشان داده است. به طور مشخص، مقدار F1-score این مدل برای کلاس تقلب ۰/۸۵ است که نسبت به درخت تصمیم با مقدار ۰/۸۰ و رگرسیون لجستیک با مقدار ۰/۶۹ بیشتر است و با KNN با مقدار ۰/۸۲ نیز عملکرد بهتری دارد. همچنین مقدار Precision برابر با ۰/۹۳ در کنار Recall برابر با ۰/۷۹ نشان می‌دهد که XGBoost گزینه مناسبی برای استفاده در مرحله بعدی، یعنی ترکیب مدل‌ها در روش Ensemble است.

۲.۵. جنگل تصادفی

جنگل تصادفی از تعداد زیادی درخت تصمیم تشکیل شده است. هر درخت روی نمونه‌ها و ویژگی‌های متفاوتی آموزش داده می‌شود و در نهایت خروجی درخت‌ها با یکدیگر ترکیب می‌شوند. احتمال تعلق یک نمونه به کلاس تقلب را می‌توان به صورت زیر در نظر گرفت:

$$P(y=1|x) = \frac{1}{T} \sum_{t=1}^T P_t(y=1|x)$$

که در آن T تعداد درخت‌ها است. مزیت مهم جنگل تصادفی کاهش واریانس و کاهش احتمال بیش‌برازش نسبت به یک درخت تصمیم منفرد است. در این پژوهش پارامترهایی مانند تعداد درخت‌ها، $\max_depth$ ، $\min_samples_split$ ، $\min_samples_leaf$ و $\max_features$ مورد بررسی قرار گرفتند. برای انتخاب تنظیمات مناسب، از Cross- K-Fold Stratified Validation و معیار F1-score استفاده شد. با توجه به عدم توازن شدید بین کلاس سالم و کلاس تقلب، در این پژوهش از پارامتر $class_weight=balanced$ استفاده شد. برای انتخاب بهترین تنظیمات جنگل تصادفی از Grid Search همراه با Stratified K-Fold Cross Validation با پنج بخش استفاده شد.

معیار انتخاب بهترین مدل، F1-score در نظر گرفته شد. در فرآیند جستجوی هایپرپارامترها، پنج پارامتر مورد بررسی قرار گرفتند.

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

وجود جمله منظم‌سازی به کنترل پیچیدگی مدل و کاهش احتمال بیش‌برازش کمک می‌کند. از آنجا که مجموعه داده دارای عدم توازن شدید بین کلاس سالم و تقلبی است، از پارامتر $scale_pos_weight$ استفاده شد. این پارامتر با استفاده از نسبت تعداد نمونه‌های کلاس سالم به تعداد نمونه‌های کلاس تقلب محاسبه شد:

$$scale_pos_weight = \frac{N_0}{N_1}$$

که در آن N_0 تعداد نمونه‌های کلاس سالم و N_1 تعداد نمونه‌های کلاس تقلب است. بنابراین، نمونه‌های کلاس اقلیت در فرآیند یادگیری وزن بیشتری دریافت می‌کنند. برای انتخاب بهترین تنظیمات XGBoost از Grid Search به همراه Stratified K-Fold Cross Validation با پنج بخش استفاده شد. معیار انتخاب بهترین مدل، F1-score در نظر گرفته شد. در فرآیند جستجوی هایپرپارامترها، شش پارامتر مورد بررسی قرار گرفتند.

• $n_estimators$: مقادیر ۳۰۰ و ۵۰۰

• $\max_depth$: مقادیر ۳، ۴ و ۵

• $learning_rate$: مقادیر ۰/۰۳ و ۰/۰۵

• $\min_child_weight$: مقادیر ۱ و ۳

• $subsample$: مقادیر ۰/۸ و ۱/۰

• $colsample_bytree$: مقادیر ۰/۸ و ۱/۰

در نتیجه تعداد کل ترکیب‌های بررسی‌شده برابر با:

$$2 \times 3 \times 2 \times 2 \times 2 \times 2 = 96$$

ترکیب بود. با توجه به استفاده از پنج Fold در Cross-Validation، در مجموع:

$$96 \times 5 = 480$$

بار آموزش و ارزیابی انجام شد. بهترین ترکیب هایپرپارامترها به صورت زیر به دست آمد:

جدول ۱۰: هایپرپارامترهای انتخاب‌شده برای XGBoost

هایپرپارامتر	مقدار انتخاب‌شده
$n_estimators$	۵۰۰
$\max_depth$	۵
$learning_rate$	۰/۰۵
$\min_child_weight$	۱
$subsample$	۰/۸
$colsample_bytree$	۱/۰

بهترین مقدار F1-score در فرآیند Cross-Validation برابر با ۰/۸۶۳۹ به دست آمد. این مقدار نشان می‌دهد که XGBoost در مرحله اعتبارسنجی توانسته است تعادل مناسبی میان Precision و Recall برای کلاس اقلیت ایجاد کند.

با Precision برابر با ۰/۹۳، Recall برابر با ۰/۷۹ و F1-score برابر با ۰/۸۵ عملکرد بهتری نسبت به جنگل تصادفی با مقادیر ۰/۹۲، ۰/۷۳ و ۰/۸۱ داشته است.

با این حال، جنگل تصادفی همچنان عملکرد مناسبی دارد و به دلیل تفاوت در ساختار یادگیری آن با XGBoost می‌تواند به عنوان یکی از مدل‌های مناسب برای مرحله بعدی یعنی روش Ensemble مورد استفاده قرار گیرد.

۳.۵. انتخاب وزن‌های Ensemble با استفاده از OOF

پس از آموزش مدل‌های Forest Random XGBoost، KNN، در این مرحله هدف انتخاب وزن مناسب برای ترکیب این سه مدل بود.

برای جلوگیری از انتخاب وزن بر اساس پیش‌بینی‌هایی که مدل در فرآیند آموزش خود مشاهده کرده است، از روش Out-of-Fold Predictions با به اختصار OOF استفاده شد.

در این روش از Stratified K-Fold Cross Validation با پنج بخش استفاده شد.

در هر Fold، مدل‌ها روی چهار بخش آموزش داده شده و روی بخش باقی‌مانده پیش‌بینی انجام دادند. بنابراین برای هر نمونه آموزشی، یک احتمال پیش‌بینی‌شده توسط مدلی به دست آمد که آن نمونه را در مرحله آموزش مشاهده نکرده بود. برای هر سه مدل، احتمال تعلق نمونه به کلاس قلب ذخیره شد:

$$P_{XGB}^{OOF}, P_{RF}^{OOF}, P_{KNN}^{OOF}$$

سپس احتمال نهایی Ensemble به صورت ترکیب وزنی احتمال‌های سه مدل محاسبه شد:

$$P_{ensemble} = w_{XGB}P_{XGB} + w_{RF}P_{RF} + w_{KNN}P_{KNN}$$

که در آن مجموع وزن‌ها برابر با یک است:

$$w_{XGB} + w_{RF} + w_{KNN} = 1$$

برای انتخاب وزن‌ها، مقدار وزن XGBoost و Forest Random با گام ۰/۰۵ بررسی شد و وزن KNN به صورت زیر محاسبه گردید:

$$w_{KNN} = 1 - w_{XGB} - w_{RF}$$

همچنین برای احتمال نهایی، آستانه‌های مختلف از ۰/۰۵ تا ۰/۹۵ با گام ۰/۰۱ بررسی شدند.

برای هر ترکیب وزن و آستانه، معیارهای Precision، Recall و F1-score محاسبه شدند.

هدف اصلی انتخاب ترکیبی بود که شرایط زیر را برآورده کند:

$$Precision \geq 0.90$$

9

$$Recall \geq 0.80$$

در میان ترکیب‌هایی که این دو شرط را برآورده می‌کردند، ترکیبی انتخاب شد که بیشترین F1-score را داشته باشد.

در صورتی که هیچ ترکیبی نتواند به صورت همزمان دو شرط فوق را برآورده کند، ترکیبی که بیشترین F1-score را در میان تمام ترکیب‌های بررسی‌شده داشته باشد، به عنوان ترکیب نهایی انتخاب می‌شود.

روند انتخاب وزن‌ها و آستانه به صورت الگوریتمی انجام شد و پیش‌بینی‌های OOF هر سه مدل برای تمام نمونه‌های آموزشی تولید شدند.

پس از اتمام فرآیند جستجو، وزن‌های نهایی سه مدل و آستانه تصمیم به صورت زیر گزارش شدند:

• n_estimators: مقادیر ۲۰۰ و ۴۰۰

• max_depth: مقادیر ۱۰، ۱۱، ۱۲، ۱۳ و ۱۴

• min_samples_split: مقادیر ۲ و ۵

• min_samples_leaf: مقادیر ۱ و ۲

• max_features: مقدار sqrt

بنابراین تعداد کل ترکیب‌های بررسی‌شده برابر با:

$$40 \times 5 \times 2 \times 2 \times 1 = 40$$

ترکیب بود.

با توجه به استفاده از پنج Fold در Cross-Validation، در مجموع:

$$40 \times 5 = 200$$

بار آموزش و ارزیابی انجام شد.

بهترین ترکیب هایپرپارامترها به صورت زیر به دست آمد:

جدول ۱۲: هایپرپارامترهای انتخاب‌شده برای جنگل تصادفی

هایپرپارامتر	مقدار انتخاب‌شده
n_estimators	۲۰۰
max_depth	۱۳
min_samples_split	۲
min_samples_leaf	۲
max_features	sqrt

بهترین مقدار F1-score در فرآیند Cross-Validation برابر با ۰/۸۴۹۵ به دست آمد.

پس از انتخاب بهترین هایپرپارامترها، مدل نهایی با استفاده از تمام داده‌های آموزشی آموزش داده شد و سپس روی مجموعه آزمون ارزیابی گردید.

جدول ۱۳: نتایج مدل جنگل تصادفی روی مجموعه آزمون

Support	F1-score	Recall	Precision	کلاس
۵۶۶۵۱	۱/۰۰	۱/۰۰	۱/۰۰	۰
۹۵	۰/۸۱	۰/۷۳	۰/۹۲	۱
۵۶۷۴۶	۰/۹۱	۰/۸۶	۰/۹۶	Avg Macro
۵۶۷۴۶	۱/۰۰	۱/۰۰	۱/۰۰	Avg Weighted

بر اساس نتایج، جنگل تصادفی برای کلاس اقلیت دارای Precision برابر با ۰/۹۲، Recall برابر با ۰/۷۳ و F1-score برابر با ۰/۸۱ است.

مدل توانسته است حدود ۷۳ درصد از تراکنش‌های تقلبی موجود در مجموعه آزمون را شناسایی کند.

مقدار Precision برابر با ۰/۹۲ نشان می‌دهد که مدل در تشخیص تراکنش‌های تقلبی دقت مناسبی دارد.

مقدار F1-score برابر با ۰/۸۱ نیز نشان‌دهنده تعادل مناسب میان Precision و Recall برای کلاس اقلیت است.

مقایسه مقدار F1-score حاصل از Cross-Validation با نتیجه مجموعه آزمون نشان می‌دهد که مقدار این معیار از ۰/۸۴۹۵ در فرآیند اعتبارسنجی به ۰/۸۱ در مجموعه آزمون کاهش یافته است. این اختلاف نشان می‌دهد که عملکرد مدل روی داده‌های آزمون کمی پایین‌تر از عملکرد متوسط آن در فرآیند اعتبارسنجی بوده است.

در مقایسه با XGBoost، جنگل تصادفی در این آزمایش عملکرد ضعیف‌تری در تشخیص کلاس قلب داشته است. XGBoost

جدول ۱۴: پارامترهای انتخاب شده برای Ensemble

پارامتر	مقدار
وزن XGBoost	۰/۴۵
وزن Forest Random	۰/۴۵
وزن KNN	۰/۱۰
آستانه تصمیم	۰/۵۶
OOF روی F1-score	۰/۸۷۲۷

مقادیر نهایی جدول فوق مستقیماً از اجرای فرآیند OOF و جستجوی وزن‌ها و آستانه استخراج می‌شوند.

نکته مهم این است که در این مرحله، داده‌های مجموعه آزمون برای انتخاب وزن‌ها و آستانه استفاده نشده‌اند. بنابراین مجموعه آزمون همچنان به عنوان یک مجموعه مستقل برای ارزیابی نهایی عملکرد Ensemble حفظ می‌شود.

۴.۵. نتایج Ensemble

در مرحله نهایی، احتمال‌های تولیدشده توسط سه مدل XG-Boost، Forest Random و KNN با استفاده از یک ترکیب وزنی با یکدیگر ادغام شدند.

برای انتخاب وزن‌های مناسب، از Out-of-Fold Predictions حاصل از Stratified K-Fold Cross Validation با پنج بخش استفاده شد.

در فرآیند جستجو، وزن‌های XGBoost و Forest Random با گام ۰/۰۵ بررسی شدند و وزن KNN به گونه‌ای تعیین شد که مجموع وزن‌های سه مدل برابر با یک باشد. همچنین آستانه‌های مختلف بین ۰/۰۵ و ۰/۹۵ با گام ۰/۰۱ مورد بررسی قرار گرفتند.

هدف، انتخاب ترکیبی بود که در صورت امکان دارای Precision حداقل ۰/۹۰ و Recall حداقل ۰/۸۰ باشد و در میان ترکیب‌های مجاز، بیشترین F1-score را ایجاد کند. در نهایت، بهترین ترکیب بر اساس پیش‌بینی‌های OOF به صورت زیر به دست آمد:

$$w_{XGB} = 0.45$$

$$w_{RF} = 0.45$$

$$w_{KNN} = 0.10$$

همچنین آستانه تصمیم برابر با:

$$\tau = 0.56$$

انتخاب شد. بنابراین احتمال نهایی Ensemble به صورت زیر محاسبه می‌شود:

$$P_{ensemble} = 0.45P_{XGB} + 0.45P_{RF} + 0.10P_{KNN}$$

و بر اساس آستانه ۰/۵۶، برچسب نهایی نمونه‌ها تعیین می‌شود:

$$\hat{y} = \begin{cases} 1 & P_{ensemble} \geq 0.56 \\ 0 & P_{ensemble} < 0.56 \end{cases}$$

مقدار F1-score به دست آمده از پیش‌بینی‌های OOF برابر با ۰/۸۷۲۷ بود. نتایج نهایی مدل Ensemble روی مجموعه آزمون به صورت زیر به دست آمد:

جدول ۱۵: نتایج نهایی Ensemble روی مجموعه آزمون

پارامتر	مقدار
وزن XGBoost	۰/۴۵
وزن Forest Random	۰/۴۵
وزن KNN	۰/۱۰
Threshold	۰/۵۶
Precision	۰/۹۷۳۰
Recall	۰/۷۵۷۹
F1-score	۰/۸۵۲۱
PR-AUC	۰/۸۲۵۳

همان‌طور که مشاهده می‌شود، مدل Ensemble روی مجموعه آزمون به Precision برابر با ۰/۹۷۳۰ دست یافته است. مقدار Recall برابر با ۰/۷۵۷۹ است. بنابراین مدل توانسته است ۷۲ مورد از مجموع ۹۵ تراکنش تقلبی موجود در مجموعه آزمون را به درستی شناسایی کند. مقدار F1-score نیز برابر با ۰/۸۵۲۱ به دست آمده است که نشان‌دهنده تعادل مناسبی میان Precision و Recall است. ماتریس درهم‌ریختگی مدل Ensemble به صورت زیر به دست آمد:

جدول ۱۶: ماتریس درهم‌ریختگی Ensemble

پیش‌بینی کلاس ۰	پیش‌بینی کلاس ۱	واقعی کلاس ۰
۵۶۶۴۹	۲	۲۳
۷۲	۷۲	۷۲

بر اساس ماتریس درهم‌ریختگی، مدل تنها ۲ نمونه سالم را به اشتباه به عنوان تقلب شناسایی کرده است. در مقابل، از مجموع ۹۵ نمونه تقلبی، ۷۲ نمونه به درستی شناسایی شده و ۲۳ نمونه از دست رفته‌اند.

مقدار PR-AUC مدل نیز برابر با ۰/۸۲۵۳ به دست آمد. این معیار با توجه به نامتوازن بودن شدید داده‌ها، معیار مناسبی برای ارزیابی عملکرد مدل در تشخیص کلاس اقلیت محسوب می‌شود.

در مقایسه با مدل‌های منفرد، Ensemble توانسته است Precision بسیار بالایی ایجاد کند. برای مثال، XGBoost به تنهایی دارای Precision برابر با ۰/۹۳، Recall برابر با ۰/۷۹ و F1-score برابر با ۰/۸۵ بود، در حالی که Ensemble به Precision برابر با ۰/۹۷ و F1-score برابر با ۰/۸۵ دست یافت.

با این حال، Ensemble Recall برابر با ۰/۷۶ است که نسبت به Recall برابر با ۰/۷۹ در XGBoost کمتر است. بنابراین ترکیب مدل‌ها در این آزمایش باعث افزایش Precision و کاهش تعداد مثبت‌های کاذب شده است، اما به قیمت کاهش نسبی Recall تمام شده است.

همچنین مقدار F1-score حاصل از OOF برابر با ۰/۸۷۲۷ و مقدار آن روی مجموعه آزمون برابر با ۰/۸۵۲۱ است. کاهش محدود این معیار از مرحله OOF به مجموعه آزمون نشان می‌دهد که عملکرد مدل روی داده‌های دیده‌نشده همچنان در سطح مناسبی باقی مانده است.

با توجه به اینکه هدف اولیه انتخاب ترکیب شامل Precision حداقل ۰/۹۰ و Recall حداقل ۰/۸۰ بود، ترکیب انتخاب‌شده روی مجموعه آزمون نتوانسته است شرط Recall برابر با ۰/۸۰ را حفظ کند.

بنابراین می‌توان گفت که این ترکیب در مجموعه آموزش و پیش‌بینی‌های OOF عملکرد بسیار خوبی داشته، اما روی مجموعه آزمون Recall آن به حدود ۰/۷۶ کاهش یافته است.

۶. نتایج کلی و تحلیل مقایسه‌ای

در این بخش، عملکرد تمام مدل‌های بررسی‌شده با یکدیگر مقایسه می‌شود. با توجه به نامتوازن بودن شدید مجموعه داده، تمرکز اصلی بر روی عملکرد مدل در شناسایی کلاس اقلیت، یعنی تراکنش‌های تقلبی، قرار گرفته است. بنابراین معیارهای Precision، Recall و F1-score نسبت به Accuracy اهمیت بیشتری دارند. نتایج نهایی مدل‌ها در جدول زیر خلاصه شده است:

جدول ۱۷: مقایسه عملکرد مدل‌های مختلف روی مجموعه آزمون

مدل	Precision	Recall	F1-score
Tree Decision	۰/۹۲	۰/۷۱	۰/۸۰
KNN	۰/۹۶	۰/۷۲	۰/۸۲
Regression Logistic	۰/۸۵	۰/۵۸	۰/۶۹
Forest Random	۰/۹۲	۰/۷۳	۰/۸۱
XGBoost	۰/۹۳	۰/۷۹	۰/۸۵
Ensemble	۰/۹۷	۰/۷۶	۰/۸۵

با توجه به نتایج جدول، رگرسیون لجستیک با F1-score برابر با ۰/۶۹ ضعیف‌ترین عملکرد را در میان مدل‌های بررسی‌شده داشته است.

همچنین Recall برابر با ۰/۵۸ نشان می‌دهد که این مدل بخش قابل توجهی از تراکنش‌های تقلبی را از دست داده است. این نتیجه نشان می‌دهد که مدل‌های خطی در این آزمایش توانایی کمتری برای مدل‌سازی روابط پیچیده و غیرخطی موجود در داده‌ها داشته‌اند.

در میان مدل‌های پایه، KNN بهترین عملکرد را با F1-score برابر با ۰/۸۲ نشان داده است.

این مدل همچنین به Precision برابر با ۰/۹۶ دست یافته است؛ بنابراین تعداد نمونه‌های سالمی که به اشتباه به عنوان تقلب شناسایی شده‌اند، نسبتاً کم بوده است.

جنگل تصادفی با F1-score برابر با ۰/۸۱ عملکردی نزدیک به KNN داشته است.

با این حال، Recall برابر با ۰/۷۳ نشان می‌دهد که این مدل نسبت به XGBoost تعداد بیشتری از تراکنش‌های تقلبی را از دست داده است.

بهترین عملکرد در میان مدل‌های منفرد مربوط به XGBoost بوده است. این مدل با Precision برابر با ۰/۹۳، Recall برابر با ۰/۷۹ و F1-score برابر با ۰/۸۵ توانسته است بهترین تعادل میان تشخیص صحیح تراکنش‌های تقلبی و جلوگیری از ایجاد مثبت‌های کاذب را ایجاد کند.

مقایسه XGBoost با Forest Random نیز نشان می‌دهد که XGBoost در هر سه معیار اصلی عملکرد بهتری داشته است. مقدار Recall از ۰/۷۳ به ۰/۷۹، Forest Random به ۰/۷۹ در XGBoost افزایش یافته و F1-score نیز از ۰/۸۱ به ۰/۸۵ رسیده است. این نتیجه نشان می‌دهد که ساختار ترتیبی و فرآیند Boosting در XGBoost در این مجموعه داده توانسته است روابط پیچیده‌تری را نسبت به روش Bagging جنگل تصادفی مدل کند. در مرحله نهایی، سه مدل XGBoost، Forest Random و KNN با استفاده از یک Ensemble وزنی ترکیب شدند.

وزن‌های انتخاب‌شده شامل ۰/۴۵ برای XGBoost، ۰/۴۵ برای Forest Random و ۰/۱۰ برای KNN بودند.

همچنین آستانه تصمیم برابر با ۰/۵۶ انتخاب شد. Ensemble توانست Precision را از ۰/۹۳ به ۰/۹۷ و Recall را از ۰/۷۹ به ۰/۸۵ افزایش دهد.

همچنین تعداد مثبت‌های کاذب در مجموعه آزمون تنها ۲ مورد بود.

این موضوع نشان می‌دهد که ترکیب مدل‌ها در کاهش False Positive عملکرد بسیار خوبی داشته است.

با این حال، افزایش Precision با کاهش Recall همراه بوده است. Ensemble مدل برابر با ۰/۷۶ بوده، در حالی که این مقدار برای XGBoost برابر با ۰/۷۹ است. بنابراین Ensemble در آزمایش حاضر نتوانسته است از نظر شناسایی تعداد بیشتری از تراکنش‌های تقلبی نسبت به XGBoost عملکرد بهتری داشته باشد. مقدار F1-score هر دو مدل XGBoost و Ensemble برابر با ۰/۸۵ تقریباً است.

بنابراین بر اساس معیار F1-score، ترکیب مدل‌ها مزیت مشخصی نسبت به XGBoost به تنهایی ایجاد نکرده است. با این حال، Ensemble زمانی مزیت بیشتری دارد که کاهش مثبت‌های کاذب و افزایش Precision اهمیت بیشتری داشته باشد.

یکی دیگر از نتایج مهم این آزمایش، تفاوت میان عملکرد OOF و عملکرد مجموعه آزمون است. مقدار F1-score برای Ensemble در پیش‌بینی‌های OOF برابر با ۰/۸۷۲۷ بود، در حالی که این مقدار روی مجموعه آزمون به ۰/۸۵۲۱ رسید.

این کاهش نشان می‌دهد که عملکرد مدل روی داده‌های کاملاً دیده‌نشده کمی پایین‌تر از عملکرد آن در فرآیند انتخاب وزن‌ها بوده است.

در مجموع، نتایج نشان می‌دهد که انتخاب بهترین مدل به هدف سیستم تشخیص تقلب بستگی دارد. اگر هدف اصلی ایجاد تعادل میان Precision و Recall و شناسایی تعداد بیشتری از تراکنش‌های تقلبی باشد، XGBoost در این آزمایش بهترین گزینه است. از طرف دیگر، اگر کاهش مثبت‌های کاذب اهمیت بیشتری داشته باشد، Ensemble با Precision برابر با ۰/۹۷ گزینه مناسب‌تری خواهد بود.

بنابراین، بر اساس نتایج مجموعه آزمون، XGBoost را می‌توان به عنوان بهترین مدل منفرد این پژوهش در نظر گرفت، در حالی که Ensemble نشان داده است که ترکیب مدل‌ها لزوماً بهبود همزمان تمام معیارهای ارزیابی را تضمین نمی‌کند و انتخاب وزن‌ها و آستانه تصمیم نقش مهمی در تعیین نقطه تعادل میان Precision و Recall دارد.

مراجع

- [۱] Pei, J. and Kamber, M. Han, J. Techniques. and Concepts Mining: Data
- [۲] Courville, A. and Bengio, Y. Goodfellow, I. Learning, Deep Press, MIT ۲۰۱۶.
- [۳] Bishop, M. C. Learning, Machine and Recognition Pattern Springer, ۲۰۰۶.